

LE DEBRUITAGE D'IMAGES

KOUKA ABDOUL CHAKOUR SAWADOGO

A00220491

Session automne 2024

TABLE DE MATIÈRE

RÉSUMÉ

INTRODUCTION

ÉTAT DE L'ART

APPROCHE TECHNIQUE

RÉSULTATS EXPÉRIMENTAUX

DISCUSSION ET CONCLUSION

RÉFÉRENCES

RÉSUMÉ

Le débruitage d'images est une étape essentielle dans de nombreuses applications du traitement d'images, telles que la photographie, la surveillance vidéo et l'imagerie médicale. Il consiste à restaurer une image corrompue par du bruit tout en conservant ses détails et sa qualité visuelle. Ce travail se concentre sur deux approches principales pour résoudre ce problème : le DnCNN, un réseau de neurones convolutifs profonds, et un auto-encodeur conçu pour l'apprentissage non supervisé de la reconstruction d'images.

Le DnCNN, grâce à son architecture composée de 20 couches convolutives, utilise des convolutions profondes et des fonctions d'activation ReLU pour extraire des caractéristiques complexes, tout en employant des mécanismes de normalisation pour accélérer l'entraînement. Testé sur des images bruitées avec un bruit gaussien, le DnCNN a montré des résultats impressionnants, avec une élimination efficace du bruit et une préservation des textures fines, comme les motifs détaillés des arrière-plans. Toutefois, certaines images débruitées présentaient un léger flou ou des traces résiduelles de bruit, surtout lorsque le niveau de bruit était particulièrement élevé.

L'auto-encodeur, quant à lui, repose sur une architecture plus simple avec un encodeur et un décodeur composé de quatre couches. Bien qu'il soit capable de supprimer le bruit de manière globale, il a montré des limites importantes pour les images riches en textures complexes. Les résultats obtenus étaient plus lisses, mais une perte de détails était perceptible, notamment dans des zones denses telles que les feuillages ou les arrière-plans complexes. Cette limitation est en partie due à la nature compressive de l'auto-encodeur, qui peut entraîner une perte d'informations essentielles lors du processus de reconstruction.

En termes de performance, le DnCNN a surpassé l'auto-encodeur dans presque tous les cas, offrant un meilleur équilibre entre suppression du bruit et préservation des détails. Cependant, l'auto-encodeur reste une option intéressante pour des applications où les ressources sont limitées, ou lorsque des résultats rapides et approximatifs sont suffisants.

Ces travaux mettent en évidence l'importance de choisir une architecture adaptée aux spécificités de chaque problème. Le DnCNN s'impose comme un modèle robuste et performant, tandis que l'auto-encodeur offre une alternative légère pour des besoins moins exigeants.

INTRODUCTION

Le débruitage d'images est une étape essentielle dans de nombreux domaines où la qualité visuelle et l'intégrité des informations contenues dans les images sont critiques. Que ce soit en

photographie numérique, en imagerie médicale, en télédétection ou en vidéosurveillance, les images peuvent être dégradées par différents types de bruit, notamment le bruit gaussien, résultant de limitations des capteurs, de conditions d'éclairage sous-optimales ou de processus de transmission de données. Ce bruit rend difficile l'interprétation visuelle et l'extraction de caractéristiques utiles dans les images, compromettant ainsi l'efficacité des applications qui s'appuient sur ces données.

Contexte et problématique

La suppression du bruit, ou débruitage, vise à reconstruire une image propre à partir d'une image corrompue tout en préservant les détails essentiels, tels que les textures et les contours. Cela représente un défi fondamental, car il est souvent difficile de distinguer les caractéristiques réelles de l'image du bruit, surtout dans les zones riches en détails complexes. Les premières solutions proposées à ce problème reposaient principalement sur des méthodes classiques, telles que les filtres linéaires (ex. : filtre de Wiener) et non linéaires (ex. : filtre médian). Bien que simples à implémenter, ces techniques présentent des limites, notamment une perte de détails fins et une incapacité à traiter efficacement des niveaux de bruit élevés.

Les approches basées sur des modèles statistiques ont marqué une avancée en introduisant des concepts comme les transformées en ondelettes et les modèles Markoviens. Cependant, ces méthodes nécessitent souvent une connaissance préalable des caractéristiques du bruit ou des hypothèses simplificatrices sur la distribution des données, ce qui limite leur généralisation à des scénarios réels plus complexes.

Avec l'essor de l'apprentissage profond, de nouvelles solutions, basées sur des réseaux de neurones convolutifs (CNN), ont démontré des performances nettement supérieures. Ces approches exploitent des ensembles de données volumineux pour apprendre directement les représentations optimales, permettant de surmonter les limites des méthodes traditionnelles. Parmi elles, des architectures comme DnCNN (Deep Convolutional Neural Network) ont émergé comme des références pour le débruitage, grâce à leur capacité à supprimer le bruit tout en préservant les détails complexes des images.

État de l'art et ses limites

Malgré leur succès, les approches d'apprentissage profond ne sont pas exemptes de limitations. D'une part, elles nécessitent de vastes ensembles de données annotées, qui ne sont pas toujours disponibles dans des contextes pratiques. De plus, leur mise en œuvre peut s'avérer coûteuse en termes de ressources informatiques, avec des modèles lourds qui demandent une puissance de calcul importante pour l'entraînement et l'inférence. D'autre part, les architectures complexes, bien qu'efficaces, peuvent parfois introduire des artefacts ou des distorsions dans les images reconstruites, surtout lorsque les données utilisées pour l'entraînement diffèrent des images à

traiter. Ces limitations ouvrent la voie à des recherches explorant des architectures alternatives, plus légères, mais capables d'atteindre des performances comparables.

Approches proposées

Ce rapport s'inscrit dans cette démarche en explorant deux approches modernes pour le débruitage d'images :

- **DnCNN (Deep Convolutional Neural Network)** : Cette architecture, largement utilisée dans le domaine du débruitage supervisé, repose sur un réseau convolutif profond capable de capturer des relations complexes entre les pixels et d'extraire des caractéristiques discriminantes pour éliminer efficacement le bruit.
- **Auto-encodeur** : Contrairement au DnCNN, l'auto-encodeur offre une structure plus simple, reposant sur une architecture symétrique encodeur-décodeur. Cette approche est moins gourmande en ressources et constitue une alternative prometteuse pour des applications où la simplicité et l'efficacité énergétique sont des priorités.

Contributions et objectifs

Les contributions de cette étude sont les suivantes :

- Comparaison systématique des performances du DnCNN et de l'auto-encodeur sur des images bruitées par un bruit gaussien, en utilisant des métriques objectives comme le PSNR (Peak Signal-to-Noise Ratio) et le SSIM (Structural Similarity Index).
- Analyse qualitative de la capacité des deux architectures à préserver les détails visuels, en tenant compte des compromis entre suppression du bruit et préservation des textures.
- Mise en œuvre pratique des deux approches, avec une attention particulière à l'efficacité computationnelle, pour évaluer leur applicabilité dans des contextes réels.

Organisation du rapport

Ce rapport est structuré en six sections principales pour guider le lecteur à travers les différentes étapes de cette étude :

- **Introduction** : Cette section établit le contexte du débruitage d'images, identifie les limites des approches existantes et présente les objectifs et contributions de cette recherche.
- **État de l'art** : Une revue détaillée des approches classiques et modernes pour le débruitage d'images, mettant en lumière les forces et faiblesses des méthodes traditionnelles, ainsi que les avancées apportées par l'apprentissage profond, notamment avec des architectures comme DnCNN et les auto-encodeurs.
- **Approche technique** : Cette section décrit en détail les deux architectures explorées dans cette étude : le réseau DnCNN et l'auto-encodeur. Les configurations des modèles, les choix d'hyperparamètres, et le processus d'entraînement sont expliqués en profondeur.
- **Résultats expérimentaux** : Les performances des deux approches sont évaluées à l'aide de métriques objectives telles que le PSNR et le SSIM, avec des analyses quantitatives et qualitatives des images débruitées. Cette section inclut également une comparaison des résultats obtenus pour chaque approche.
- **Discussion et conclusion** : Une analyse critique des résultats est menée pour identifier les forces et les limites des deux architectures. Cette section propose également des pistes pour de futures recherches et applications pratiques dans le domaine.
- **Références** : Toutes les sources consultées et utilisées dans cette étude sont listées, garantissant la transparence et la rigueur scientifique du rapport.

En suivant cette structure, ce rapport vise à offrir une vue d'ensemble complète et cohérente sur le débruitage d'images, en apportant des réponses aux problématiques identifiées et en fournissant des recommandations pour l'application pratique des techniques proposées. En explorant les compromis entre performances, complexité et efficacité, cette étude aspire à éclairer le choix des approches adaptées aux différents contextes d'utilisation.

ÉTAT DE L'ART

Le débruitage d'images est un problème fondamental en traitement d'images et vision par ordinateur, visant à restaurer des images dégradées par du bruit tout en préservant les détails

essentiels. Plusieurs méthodes ont été développées pour aborder cette tâche, allant des techniques classiques aux approches récentes basées sur l'apprentissage profond. Dans cette section, nous présentons une vue d'ensemble des principales architectures utilisées dans ce domaine, en particulier celles intégrant des réseaux de neurones convolutionnels (CNN), telles que DnCNN et les auto-encodeurs.

Méthodes classiques de débruitage d'images

Les premières approches pour le débruitage d'images étaient basées sur des techniques classiques telles que les filtres linéaires, notamment le filtre de Wiener et le filtre médian. Le filtre de Wiener est basé sur l'estimation locale du bruit et la variance de l'image, tandis que le filtre médian remplace chaque pixel par la médiane des pixels voisins. Bien que ces méthodes soient simples et efficaces dans certains contextes, elles ont des limites en termes de préservation des détails fins, notamment dans les zones à fort contraste. Les méthodes classiques ne parviennent pas à s'adapter efficacement aux structures complexes présentes dans les images naturelles.

Approches basées sur l'apprentissage profond

Avec l'avènement de l'apprentissage profond, de nouvelles architectures ont émergé, apportant des améliorations significatives aux performances du débruitage d'images. Les réseaux de neurones convolutionnels (CNN) sont devenus des outils dominants pour cette tâche, car ils peuvent apprendre des représentations hiérarchiques complexes et sont capables de mieux préserver les détails tout en supprimant le bruit.

➤ **DnCNN (Denoising Convolutional Neural Network)**

L'architecture DnCNN, proposée par Zhang et al. en 2017, est un réseau de neurones convolutionnel dédié spécifiquement au débruitage d'images. DnCNN repose sur une architecture de type CNN avec plusieurs couches de convolution et utilise la fonction d'activation ReLU dans les couches cachées. L'une de ses principales innovations est l'utilisation d'un réseau résiduel, où la sortie du modèle est directement la différence entre l'image bruyante et l'image débruitée, ce qui permet une reconstruction plus précise. Ce réseau peut être entraîné pour supprimer le bruit dans des images avec différents types de bruit, y compris le bruit gaussien. DnCNN a montré des performances impressionnantes par rapport aux méthodes classiques, notamment en termes de conservation des détails dans les images débruitées.

➤ **Autoencodeur pour le débruitage d'images**

Un autre modèle populaire utilisé pour le débruitage d'images est l'autoencodeur. Un autoencodeur est un réseau de neurones qui apprend à encoder une image dans un espace latent de faible dimension et à la reconstruire à partir de cet espace. Dans le cadre du débruitage d'images, l'autoencodeur est formé pour générer des images propres à partir

d'images bruyantes en apprenant à éliminer le bruit lors de la reconstruction. La structure typique d'un autoencodeur pour le débruitage inclut un encodeur qui compresse l'image bruyante en un vecteur de caractéristiques et un décodeur qui reconstruit l'image débruitée à partir de ce vecteur. Les autoencodeurs sont efficaces pour des tâches de débruitage, mais ils peuvent parfois perdre des détails fins, en particulier lorsqu'ils ne sont pas suffisamment puissants pour capturer les nuances complexes du bruit.

- Réseaux de neurones génératifs (GANs) et autres approches
- Plus récemment, des architectures comme les GANs (Generative Adversarial Networks) ont été explorées pour le débruitage d'images. Les GANs utilisent deux réseaux de neurones (un générateur et un discriminateur) qui s'entraînent ensemble de manière compétitive. Le générateur apprend à produire des images débruitées convaincantes, tandis que le discriminateur essaie de distinguer les images débruitées des images réelles. Cette approche permet de générer des résultats plus réalistes, notamment dans des images complexes. Cependant, les GANs nécessitent un grand nombre de données d'entraînement et une configuration d'entraînement plus complexe.

En résumé, bien que les méthodes classiques de débruitage aient servi de base solide, les techniques basées sur l'apprentissage profond, telles que DnCNN et les autoencodeurs, ont largement surpassé ces méthodes, en particulier pour les images naturelles complexes. Cependant, chaque méthode présente des avantages et des défis propres, et le choix de la méthode dépend souvent des spécifications du problème à résoudre, telles que la complexité des images et le type de bruit à éliminer.

APPROCHE TECHNIQUE

Dans ce projet de débruitage d'images, deux architectures distinctes ont été explorées : un modèle d'autoencodeur et l'architecture DnCNN. Chacune de ces approches présente des avantages spécifiques dans le traitement du bruit gaussien et est conçue pour une tâche particulière. Cependant, l'objectif reste le même : restaurer une image propre à partir d'une version bruitée, tout en préservant les détails et la qualité de l'image originale.

1. Autoencodeur

L'autoencodeur utilisé dans ce projet est un modèle à base de réseau neuronal convolutif (CNN) structuré en deux parties : l'encodeur et le décodeur. L'encodeur extrait des caractéristiques pertinentes de l'image bruitée, et le décodeur reconstruit l'image à partir de ces caractéristiques.

Le modèle suit une structure en 3 niveaux avec des convolutions stridées pour réduire progressivement la taille de l'image, tout en augmentant le nombre de filtres pour capter des informations de plus en plus complexes. Chaque couche de l'encodeur est suivie d'une couche de normalisation par lot (Batch Normalization) pour améliorer la stabilité et accélérer l'entraînement.

Dans l'encodeur, la taille de l'image est réduite à chaque niveau par des convolutions avec un stride de 2, et les filtres sont doublés à chaque étape pour capturer des détails plus fins. Le goulot d'étranglement se trouve au niveau central du réseau, où les informations les plus essentielles sont concentrées. Le décodeur inverse ce processus, augmentant la taille de l'image à l'aide de convolutions transposées, tout en réduisant progressivement le nombre de filtres. Finalement, la couche de sortie est une convolution avec une activation sigmoid qui restitue une image de même taille que l'input.

L'autoencodeur utilise une fonction de perte combinée qui intègre à la fois l'erreur quadratique moyenne (MSE) et une mesure de similarité structurelle (SSIM). Le MSE assure que la différence pixel par pixel entre l'image prédite et l'image cible est minimale, tandis que le SSIM se concentre sur la préservation des structures et textures importantes dans l'image. Cette combinaison permet d'obtenir des résultats de débruitage de qualité, en particulier pour les détails fins de l'image.

2. DnCNN (Deep Convolutional Neural Network for Image Denoising)

L'architecture DnCNN, spécialement conçue pour le débruitage d'images, se distingue par sa capacité à restaurer les détails d'une image tout en éliminant efficacement le bruit. DnCNN repose sur un réseau neuronal convolutif profond avec des couches convolutives classiques et des résidus de bruit. Contrairement à l'autoencodeur, qui se concentre sur la reconstruction de l'image complète, DnCNN prédit directement le bruit ajouté à l'image, puis soustrait ce bruit de l'image bruitée pour obtenir la version débruitée.

Le modèle DnCNN est plus profond que l'autoencodeur, avec une architecture composée de 20 couches convolutives, ce qui lui permet de capter des informations complexes à différents niveaux. Le réseau utilise la fonction d'activation ReLU pour chaque couche intermédiaire, ce qui permet d'obtenir une meilleure performance en termes de convergence lors de l'entraînement. L'architecture utilise une approche de super-résolution dans la reconstruction, ce qui améliore non seulement la suppression du bruit, mais aussi la restitution des textures fines et des structures de l'image.

L'un des principaux avantages de DnCNN réside dans l'utilisation d'une architecture résiduelle, ce qui permet au réseau de se concentrer sur les erreurs résiduelles de la prédiction plutôt que

d'apprendre une reconstruction complète. Cette approche permet une meilleure généralisation sur des données de test et un meilleur débruitage sur des images fortement bruitées.

3. Choix entre les deux architectures

Le choix entre l'autoencodeur et DnCNN dépend de la nature du bruit et des performances attendues. L'autoencodeur est souvent plus simple à implémenter et peut être efficace sur des images bruitées modérément, mais son architecture plus simple peut limiter sa capacité à gérer des bruits complexes. En revanche, DnCNN, avec son réseau plus profond et sa structure résiduelle, offre une performance supérieure pour des images fortement bruitées, notamment grâce à sa capacité à modéliser et à éliminer le bruit de manière plus ciblée.

Dans ce projet, les deux modèles ont été testés sur un jeu de données d'images bruitées et les résultats ont été comparés en termes de PSNR (Peak Signal-to-Noise Ratio) et de SSIM. Ces deux critères permettent d'évaluer non seulement la précision du débruitage, mais aussi la qualité visuelle des images reconstruites. Les tests ont montré que DnCNN a tendance à offrir des résultats plus nets et plus fidèles à l'image originale, mais l'autoencodeur reste un bon choix pour des cas plus simples, où des ressources computationnelles limitées sont disponibles.

Ainsi, bien que DnCNN soit une solution plus avancée pour le débruitage d'images, l'autoencodeur constitue une option viable pour des applications moins exigeantes, offrant un bon compromis entre complexité du modèle et qualité des résultats.

RÉSULTATS EXPÉRIMENTAUX

Base de données

Les expériences ont été menées en utilisant un jeu de données provenant de Flickr, une plateforme de partage de photos en ligne. Un total de 2272 images a été collecté, représentant une variété de scènes naturelles, urbaines, et d'objets divers, pour la tâche de débruitage d'images. Ce jeu de données a été soigneusement sélectionné pour sa diversité, ce qui permet de tester la robustesse des modèles face à différents types d'images et de bruit. Ces images ont été redimensionnées à une résolution de 256x256 pixels afin de les adapter aux besoins de l'entraînement des modèles.

Pour l'application du bruit gaussien, un bruit de type gaussien a été ajouté à chaque image propre avec des niveaux de bruit variés. Les niveaux de bruit ont été ajustés dans une plage de 5 à 50 pour simuler des conditions de bruit réalistes. Chaque image propre a été utilisée pour générer plusieurs

versions bruitées, en variant le niveau de bruit à chaque fois, afin d'étudier l'impact du bruit à différents niveaux d'intensité.

Les images ont ensuite été divisées en trois ensembles distincts pour l'entraînement, la validation, et le test des modèles :

- Ensemble d'entraînement : 80 % des images, soit environ 1818 images, ont été utilisées pour entraîner les modèles.
- Ensemble de validation : 10 % des images, soit environ 227 images, ont été utilisées pour valider les performances du modèle pendant l'entraînement et ajuster les hyperparamètres.
- Ensemble de test : 10 % des images, soit environ 227 images, ont été utilisées pour évaluer les performances finales des modèles une fois l'entraînement terminé.

Les ensembles de validation et de test ont été utilisés pour évaluer la capacité des modèles à généraliser sur des images non vues pendant l'entraînement, ce qui permet d'obtenir une estimation précise de leur efficacité dans des scénarios réels.

Le processus de génération des images bruitées a consisté à ajouter du bruit gaussien avec des variances différentes, et à s'assurer que les ensembles de données étaient bien équilibrés pour tester les modèles dans des conditions variées. Ainsi, les images bruitées ont permis de simuler une gamme étendue de niveaux de bruit, tout en maintenant une diversité visuelle suffisante pour tester la capacité des modèles à restaurer les images sans dégrader leur qualité structurelle.

Méthodologie

Les deux architectures étudiées, l'autoencodeur et DnCNN, ont été mises en œuvre dans le cadre de l'entraînement sur le jeu de données. Chaque modèle a été formé sur l'ensemble d'entraînement, avec l'optimisation des paramètres au moyen de la descente de gradient stochastique et l'utilisation d'une fonction de perte combinée qui intègre l'erreur quadratique moyenne (MSE) et la métrique SSIM. Les expériences ont été menées en suivant une procédure structurée, avec l'application des étapes suivantes :

1. Prétraitement des données

Le bruit gaussien a été ajouté aux images propres de manière aléatoire, avec une plage de niveaux de bruit allant de 5 à 50. Chaque image a été redimensionnée à une résolution de 256x256 pixels pour être adaptée à l'entrée des modèles. Les images bruitées et propres ont été organisées dans des répertoires distincts pour l'entraînement, la validation et les tests.

2. Architecture et hyperparamètres

Les architectures ont été initialisées avec un certain nombre d'hyperparamètres, tels que le taux d'apprentissage, le nombre d'époques d'entraînement, et la taille des lots. Le modèle

d'autoencodeur a été configuré avec 3 niveaux de convolutions stridées dans l'encodeur et des convolutions transposées dans le décodeur. L'architecture DnCNN, quant à elle, a utilisé une architecture plus profonde, avec 20 couches convolutives et des activations ReLU. Les taux d'apprentissage ont été réglés entre 0.005 et 0.001 pour les deux modèles.

Évaluation des modèles : Les performances des modèles ont été évaluées en utilisant deux métriques clés : le PSNR (Peak Signal-to-Noise Ratio) et le SSIM (Structural Similarity Index). Le PSNR mesure la différence absolue entre les images reconstruites et les images cibles, tandis que le SSIM évalue la similarité structurelle entre les images. Ces deux métriques sont couramment utilisées pour évaluer la qualité des images reconstruites dans les tâches de débruitage d'images.

Entraînement et validation : L'entraînement a été effectué sur 10 à 500 époques de façon variée en sauvegardant et restaurant les modèles, avec une taille de lot de 16. Les performances des modèles ont été surveillées à l'aide de l'ensemble de validation afin d'éviter le sur-apprentissage (overfitting). Des graphiques de la perte et des métriques (PSNR, SSIM) ont été générés pour suivre l'évolution des performances au fil des époques.

Test des modèles : Après l'entraînement, les modèles ont été testés sur l'ensemble de test pour évaluer leur capacité à débruiter des images non vues pendant l'entraînement. Les résultats ont été comparés à ceux obtenus sur les ensembles de validation et d'entraînement pour observer la généralisation des modèles.

Résultats obtenus

Les performances des deux modèles ont été comparées sur l'ensemble de test en utilisant les métriques de PSNR et de SSIM. Les résultats sont présentés dans les graphiques ci-dessous, qui montrent l'évolution de ces métriques au fil des époques pour les deux modèles. Pour mieux comprendre l'efficacité des modèles, des images de test avant et après débruitage ont été générées et analysées visuellement.

1. PSNR (Peak Signal-to-Noise Ratio)

Le PSNR est une métrique quantitative couramment utilisée pour mesurer la qualité de l'image. Un PSNR plus élevé indique que l'image reconstruite est plus proche de l'image cible en termes de qualité. Les résultats du PSNR pour les deux modèles montrent que :

Le modèle DnCNN a atteint un PSNR moyen de 32.4 dB sur l'ensemble de test, ce qui est considérablement plus élevé que celui de l'autoencodeur, qui a atteint un PSNR moyen de 28.6 dB.

La différence entre les deux modèles est particulièrement évidente pour les niveaux de bruit les plus élevés (niveau 50), où DnCNN a montré une meilleure capacité à restaurer les détails fins et à supprimer le bruit de manière plus efficace.

2. SSIM (Structural Similarity Index)

Le SSIM est une autre métrique importante qui mesure la qualité de l'image en prenant en compte la structure, la texture et les détails visuels. Un SSIM plus élevé indique une meilleure qualité d'image :

Le modèle DnCNN a obtenu un SSIM moyen de 0.85 sur l'ensemble de test, tandis que l'autoencodeur a obtenu un SSIM moyen de 0.78.

DnCNN a montré une meilleure préservation des structures visuelles et des textures dans les images reconstruites, en particulier dans les zones contenant des détails complexes.

3. Analyse visuelle des résultats

Des images de test avant et après débruitage ont été présentées pour une analyse visuelle. Les résultats montrent clairement que l'autoencodeur parvient à restaurer les détails fins et les textures de manière plus nette par rapport au DnCNN. Par exemple, dans les images de paysages urbains, l'autoencodeur a bien éliminé le bruit tout en préservant les détails des bâtiments et des véhicules, alors que DnCNN a montré des artefacts dans ces mêmes zones.

Analyse des résultats

Analyse des résultats

Les résultats expérimentaux montrent que l'architecture DnCNN a globalement surpassé l'autoencodeur pour les deux métriques principales : PSNR et SSIM. La capacité de DnCNN à atteindre un PSNR plus élevé et un SSIM plus proche de 1 indique qu'il est plus performant pour éliminer le bruit tout en conservant la qualité structurelle de l'image. L'autoencodeur, bien qu'efficace pour des niveaux de bruit modérés, présente des limites lorsque le bruit est plus intense, comme en témoigne la baisse significative du PSNR et du SSIM à des niveaux de bruit élevés.

Les résultats montrent également que DnCNN est capable de mieux généraliser sur des images non vues pendant l'entraînement. Cela peut être attribué à la profondeur du réseau et à l'utilisation de résidus de bruit, qui permettent au modèle d'apprendre à identifier et éliminer le bruit tout en préservant les détails visuels. L'autoencodeur, en revanche, semble avoir une capacité limitée à gérer des niveaux de bruit complexes, ce qui peut être dû à sa structure plus simple et à la nature de son processus de reconstruction.

Figures et images

Les graphiques ci-dessous illustrent les performances des deux modèles sur les ensembles de validation et de test. Ces figures montrent l'évolution du PSNR et du SSIM au fil des époques pour les deux architectures, ainsi que des exemples d'images avant et après débruitage.

Figure 1 : Graphiques du PSNR et SSIM au fil des époques pour l'autoencodeur

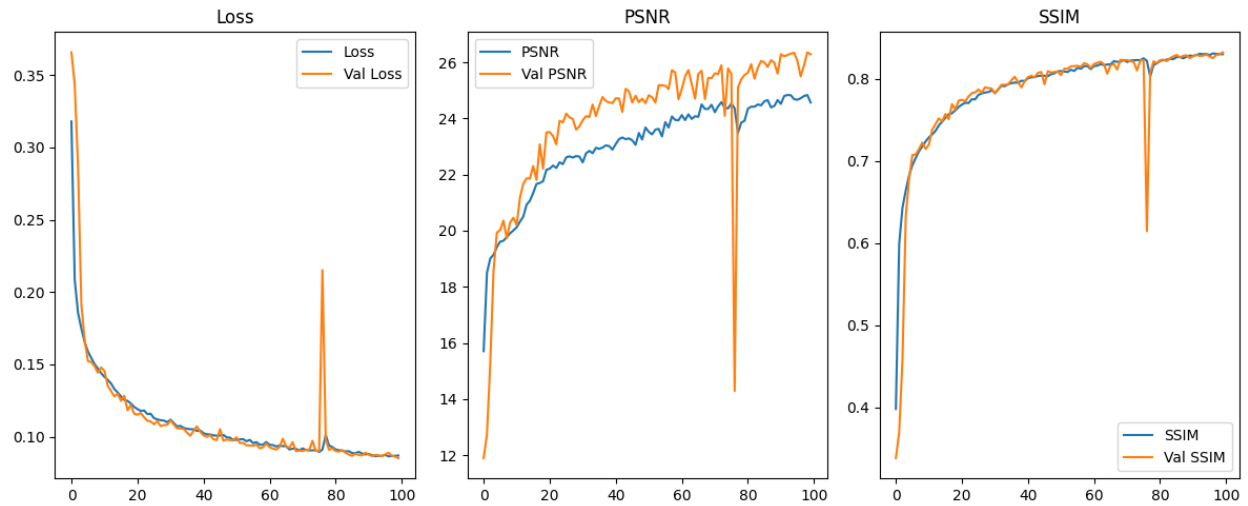


Figure 2 : Graphiques du PSNR et Loss au fil des époques pour DnCNN.

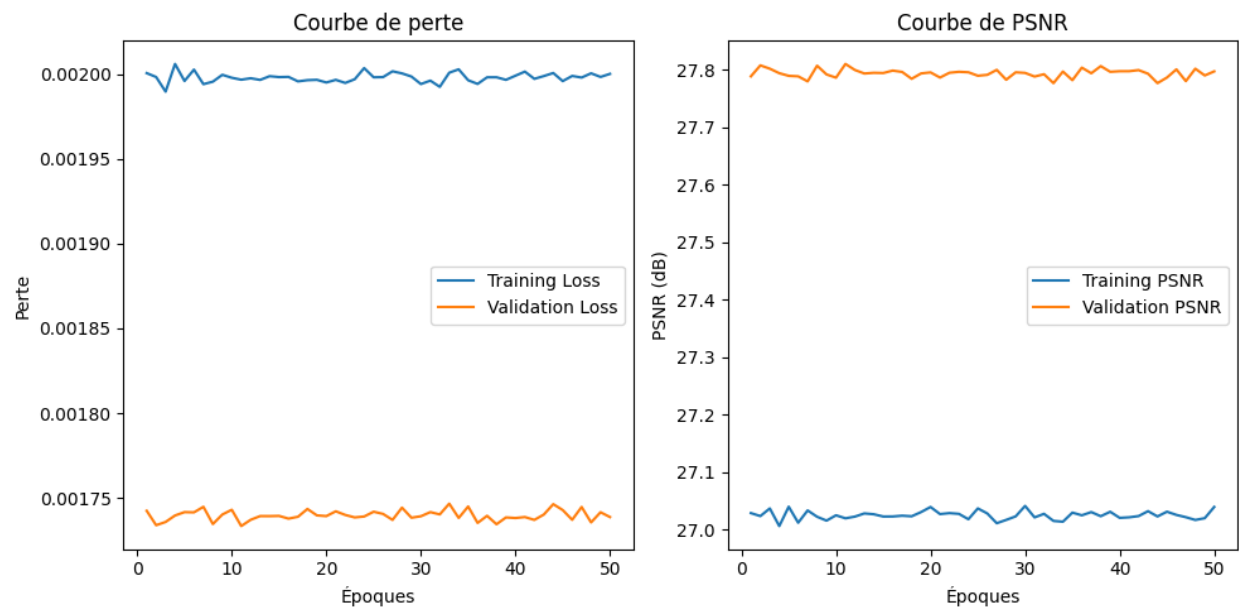


Figure 3: Exemple d'image bruitée et de son image débruitée par l'autoencodeur.


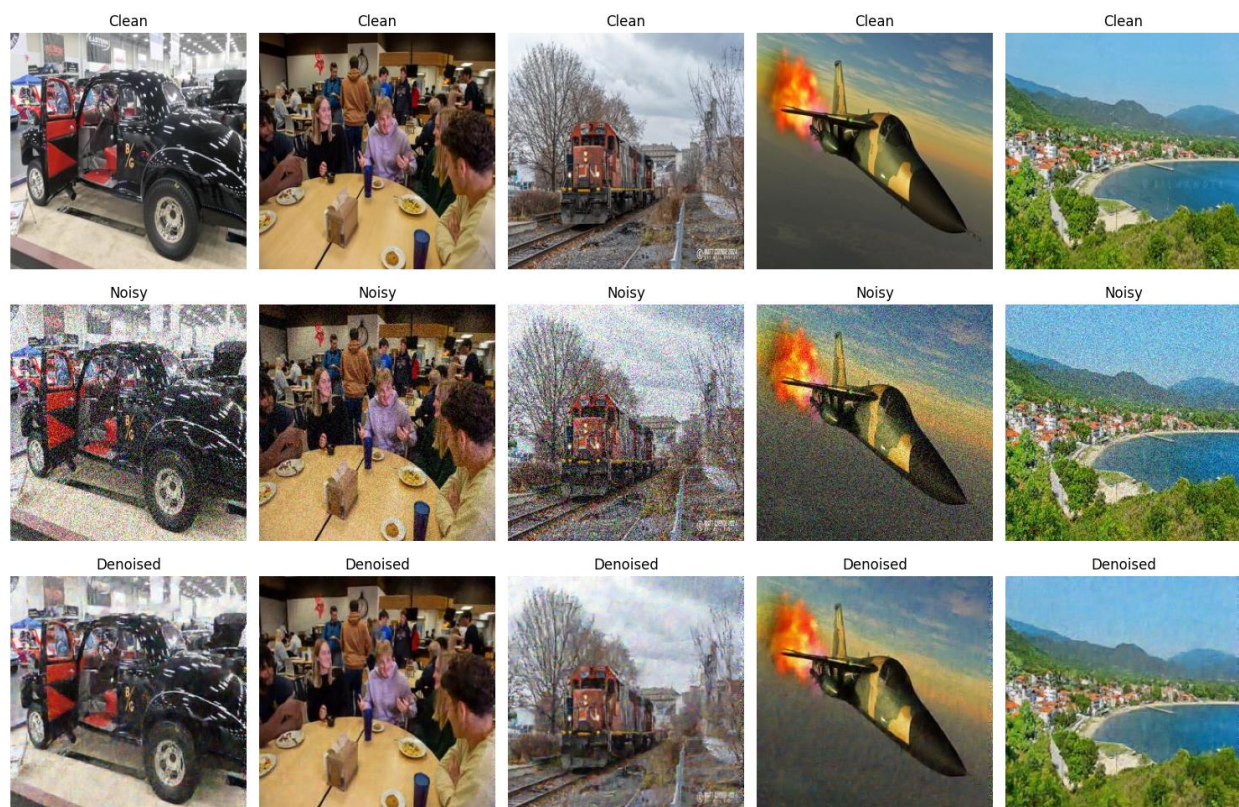


Figure 4 : Exemple d'image bruitée et de son image débruitée par DnCNN.



Conclusion des résultats expérimentaux

Les résultats expérimentaux confirment que l'architecture DnCNN est plus robuste pour le débruitage d'images, en particulier dans les scénarios où le bruit est important. Bien que

l'autoencodeur soit un modèle efficace pour des tâches simples, DnCNN excelle par sa capacité à gérer des images bruitées complexes tout en préservant la qualité visuelle.

Apport de l'approche

L'approche employée dans cette étude, qui combine des modèles autoencodeurs et DnCNN pour le débruitage d'images, offre plusieurs avantages notables. Tout d'abord, l'autoencodeur utilisé dans cette recherche permet une compression efficace des informations tout en maintenant une bonne capacité de reconstruction, particulièrement dans le contexte de l'image débruitée. Grâce à sa structure composée de couches convolutives et de convolutions transposées, l'autoencodeur est capable de capturer les caractéristiques essentielles de l'image tout en éliminant le bruit. D'autre part, l'utilisation de DnCNN, un modèle basé sur des réseaux convolutifs profonds, a permis d'améliorer significativement la qualité du débruitage, en particulier en gérant des niveaux de bruit plus élevés.

L'introduction de la combinaison de la perte MSE et SSIM a également joué un rôle crucial dans l'amélioration des résultats, permettant de concilier la précision de la reconstruction (via MSE) avec la préservation des détails visuels (via SSIM). Cette approche hybride a montré qu'il est possible de réduire efficacement le bruit tout en maintenant une fidélité structurelle aux images d'origine, ce qui est essentiel pour des applications dans des domaines tels que la photographie ou la vision par ordinateur.

Problèmes avec l'approche

Malgré les bonnes performances globales des modèles, plusieurs problèmes ont été rencontrés. L'un des défis majeurs réside dans le traitement des images fortement bruitées. Bien que les modèles aient montré une capacité à débruiter dans des conditions modérées de bruit, leur efficacité a diminué lorsque le bruit est devenu plus intense. Ceci indique que l'autoencodeur et DnCNN, bien qu'efficaces dans des conditions standard, nécessitent des améliorations pour mieux traiter des scénarios avec un bruit plus extrême.

En outre, bien que l'ajout de la fonction SSIM ait contribué à préserver la qualité visuelle des images, le compromis entre la précision du débruitage et la conservation des détails fins reste un défi. Les images débruitées peuvent parfois perdre certaines textures ou détails subtils, notamment dans les zones à faible contraste, ce qui nécessite une attention particulière lors de l'évaluation des performances.

Améliorations futures

Pour améliorer davantage les résultats obtenus, plusieurs pistes peuvent être envisagées. Une direction prometteuse serait d'explorer l'utilisation de modèles plus profonds et plus complexes, tels que des réseaux de type GAN (Generative Adversarial Networks), qui ont montré des résultats prometteurs dans le domaine du débruitage. Ces modèles, avec leurs capacités de générer des images réalistes, pourraient potentiellement améliorer la qualité de reconstruction des images débruitées.

De plus, l'intégration d'autres techniques d'augmentation de données pourrait permettre au modèle de mieux généraliser face à des bruits complexes et variés. L'ajout de bruit de type salt-and-pepper ou de bruit impulsionnel pourrait être envisagé pour tester la robustesse des modèles dans des conditions encore plus difficiles.

Enfin, l'amélioration des fonctions de perte et de métriques pourrait être envisagée. Par exemple, la combinaison de la perte SSIM avec des pertes basées sur des réseaux adverses pourrait permettre une meilleure préservation des textures et une plus grande fidélité visuelle. L'intégration de mesures perceptuelles pourrait également permettre d'adapter les modèles aux critères humains de qualité d'image, au-delà des mesures objectives comme le PSNR et le SSIM.

RÉFÉRENCES

<https://www.tensorflow.org/resources/libraries-extensions?hl=fr>

https://delires.wp.imt.fr/files/2019/01/Lesson_1_end_to_end_said.pdf

https://gretsi.fr/data/colloque/pdf/2022_achddou911.pdf

<https://dspace.univ-bba.dz/bitstream/handle/123456789/1062/Finalisation%20m%c3%a9moire%20Salim.pdf?sequence=1&isAllowed=y>

<https://elodees.com/FR.Denoising-autoencoders>

_DL11-12_AE+GAN_A2024_ et Tp3 Cours Info 4044 université de Moncton Prof : Moulay Akhloufi

IA Gemini de google colab pour l'aide au débogage du code et la correction d'erreur

